Adaptación del Modelo Matemático LIF para Predicción Temprana de Lluvia con una hora de Anticipación

Peralta, Alexis Tomas

Universidad Tecnológica Nacional, Facultad Regional Villa Maria

Resumen

La lluvia es un fenómeno meteorológico cuya predicción precisa es compleja, debido a la gran cantidad de variables atmosféricas que intervienen en su formación. Uno de los factores determinantes para su detección temprana es la tendencia de los cambios ocurridos en dichas variables. En este trabajo se propone la adaptación del modelo matemático Leaky Integrate-and-Fire (LIF), de naturaleza determinista, para la predicción horaria de lluvia, y se evalúa empíricamente su capacidad para identificar la persistencia temporal de anomalías, su dependencia de la precipitación y el aporte de su memoria temporal. Se utilizaron siete años de registros horarios (2018–2024 inclusive) de la estación EDDF (Aeropuerto de Fráncfort del Meno, Alemania), con las variables meteorológicas de entrada (temperatura, presión, humedad relativa, velocidad y dirección del viento, y precipitación), descompuestas y normalizadas junto con el contexto temporal. Se implementaron dos arquitecturas LIF, ambas se evaluaron con y sin la variable precipitación como entrada, se compararon con tres modelos de referencia mediante las métricas CSI, FAR y POD. El objetivo es determinar empíricamente la capacidad del modelo LIF para la detección temprana de lluvia y valorar el aporte de su memoria temporal frente a modelos sin memoria. Los resultados obtenidos mostraron que a pesar de esto, el mejor modelo LIF (CSI 0,403) quedó detrás del modelo persistencia (CSI 0,433), en consecuencia la hipótesis sobre la aparente ventaja de la memoria temporal no fue confirmada en el contexto actual.

Palabras Clave

Leaky Integrate-and-Fire (LIF), predicción, lluvia, modelo matemático, regresión logística, meteorología.

1 Introducción

La lluvia es un evento meteorológico provocado por diversos cambios físicos en la atmósfera, lo que denota su complejidad al momento de realizar una predicción precisa, debido a la gran cantidad de factores que intervienen en su formación. Uno de los factores determinantes para la detección temprana de lluvia es la tendencia de los cambios ocurridos en las variables meteorológicas responsables de su formación: identificar con relativa anticipación esas anomalías permitiría anticipar el evento. [1]

El modelo Leaky Integrate-and-Fire (LIF, integración y disparo con fuga en español) es un modelo matemático simplificado de una neurona, que representa una ecuación diferencial ordinaria (EDO) de primer orden. Su dinámica principal es la acumulación de potencial de membrana (V): la membrana integra la entrada con fuga (una memoria temporal, EMA) que, al alcanzar un valor definido por su umbral, genera un spike y reinicia su potencial. [2] La memoria temporal, lo diferencia de los modelos estáticos, y lo posiciona como una posible herramienta especialmente útil para identificar anomalías consecutivas como la persistencia temporal de anomalías en las variables meteorológicas.

En este contexto, el presente trabajo se propone explorar la adaptación del modelo LIF para la predicción horaria de lluvia, utilizando seis variables meteorológicas principales, descompuestas y normalizadas, junto con variables de contexto, con el fin de desarrollar un modelo predictivo a corto plazo. Se evalúa empíricamente la capacidad del modelo para identificar la persistencia temporal de anomalías previas a la lluvia, su dependencia de la variable precipitación y el aporte de su memoria temporal, mediante la comparación con modelos de referencia (persistencia, aleatoriedad y regresión logística) usando las métricas CSI, FAR y POD. [3] Se

Repositorio de programas: https://github.com/alexistpe/LIF

implementaron dos arquitecturas LIF: la primera con una única neurona de alerta y la segunda de doble capa, en la que cada variable es procesada por una neurona individual y sus salidas se combinan en una neurona de alerta. La hipótesis a verificar es si la memoria temporal del LIF proporciona una ventaja predictiva clara frente a los modelos de referencia para la predicción temprana de lluvia, lo cual se evalúa mediante las métricas de evaluación.

La utilidad esperada es disponer de una herramienta de pronóstico local de bajo costo computacional, basada en datos de estaciones meteorológicas básicas, y extensible a un mayor número de variables. El trabajo se organiza en cinco etapas: construcción y partición del dataset, diseño de los modelos de referencia, adaptación de las versiones del modelo LIF, análisis y comparación de resultados con los modelos de referencia, y por último conclusiones y trabajos futuros. Los programas creados durante este proceso se pueden encontrar en la nota de pie de página.

2 Construcción y partición del dataset

Para el entrenamiento y la evaluación de los modelos se construyó un dataset con seis variables meteorológicas (temperatura del aire, presión atmosférica, humedad relativa, velocidad y dirección del viento, y precipitación) junto con la fecha y hora de cada observación, abarcando siete años consecutivos (2018–2024 inclusive) con frecuencia horaria (una observación por hora). Se priorizó la facilidad de adquisición y la completitud de los datos, inicialmente se analizaron estaciones argentinas y se identificó una notable escasez de registros horarios de precipitación, esto motivó a buscar otra fuente, finalmente se adoptó la estación ubicada en el aeropuerto de Fráncfort del Meno (Alemania), que opera con el código OACI EDDF. La estación reporta sus registros a la agencia NOAA (National Oceanic and Atmospheric Administration) [4], que los integra en su base Integrated Surface Database (ISD); los datos se obtuvieron mediante la librería meteostat, que recupera estos registros.

2.1 Partición

El dataset (2018–2024 inclusive) se dividió en tres secciones cronológicas: Ajuste (desde 01/01/2018 00:00 hs, hasta 31/12/2022 23:00 hs, 5 años) utilizada para entrenar al modelo y calcular la climatología preliminar, Calibración (01/01/2023 00:00 hs hasta 31/12/2023 23:00 hs, 1 año) se prueban diferentes valores para los parámetros del modelo LIF, y Validación (01/01/2024 00:00 hs hasta 31/12/2024 23:00 hs, 1 año) se evalúa al modelo final obteniendo sus métricas. La última observación de cada sección se invalidó para la predicción, ya que su etiqueta no puede confirmarse al no existir la hora siguiente en esa sección. La convención para la división de fechas fue: inicio <= t < fin.

2.2 Procesamiento de las variables de entrada

Para la correcta interpretación de las variables como entrada de los modelos LIF, las variables circulares (dirección del viento, hora del día y día del año) se descompusieron en componentes cartesianas lineales, y el resto se normalizó según corresponda.

2.2.1 Descomposición circular

Una variable circular (p. ej. la dirección del viento en grados, o la hora: 23 h → 0 h) presenta saltos aparentes entre valores cercanos. Se la convierte en dos componentes lineales:
$u = -WS \cdot \sin(\theta)$, $v = -WS \cdot \cos(\theta)$ (viento);
$doy_sin = \sin(2\pi \cdot doy/365.25)$, $doy_cos = \cos(2\pi \cdot doy/365.25)$, $hod_sin = \sin(2\pi \cdot hora/24)$, $hod_cos = \cos(2\pi \cdot hora/24)$ (contexto temporal; doy = día del año, hod = hora del día). [5]

2.2.2 Normalización

El procesamiento por variable fue:

- **humedad relativa, temperatura, presión atmosférica:** anomalía mensual (valor − climatología de mes y hora) → z-score → min-max. La anomalía elimina la estacionalidad (día/noche, invierno/verano) y permite interpretar cuán anormal es el valor para esa época del año. El z-score unifica las unidades en desviaciones estándar respecto de la media ($z=(x-\mu)/\sigma$). [6]
- **Velocidad del viento:** robusto (mediana e IQR) → min-max. Usa estimadores robustos a valores extremos, al ser común las rachas extremas, este método las "tolera" sin dejar que distorsionen la separación de los valores normales, ($z_robusto=(x-mediana)/IQR$, con IQR = p75−p25), donde IQR = rango intercuartílico. [6]
- **u, v:** descomposición de la dirección del viento → robusto (mediana e IQR) → min-max.
- **precipitación:** log(1+x) → min-max. La transformación logarítmica comprime la cola pesada de la precipitación conservando los ceros (log(1+0)=0).
- **contexto:** sin/cos, sin escalado adicional (rango -1,1).

Los parámetros de todos los escaladores (media, desvío, percentiles, mínimos y máximos) se estiman sólo sobre el conjunto de Ajuste y se aplican a los demás conjuntos, evitando fuga de información.

2.3 Variable objetivo

La lluvia se define como la precipitación mensurable que alcanza el suelo [7], fijada en 0,2 mm/h. El evento se identifica con un condicional binario sobre el valor crudo en mm/h: lluvia=1 si precipitación ≥ 0,2, lluvia=0 si precipitación < 0,2. El umbral se adoptó con un criterio conservador para descartar falsos positivos por rocío.

2.4 Limitación de la climatología

La climatología de mes y hora se estimó sobre 5 años de Ajuste (frente a la normal climática de 30 años de la OMM [8]), cada celda (mes, hora) agrupa ~150 observaciones (días del mes × 5 años). Al ser una ventana corta frente a lo recomendado, se asume como una climatología preliminar.

3 Modelos de referencia

Un modelo de referencia (o baseline) es un esquema de pronóstico simple y bien definido que se utiliza como punto de comparación para cuantificar la destreza de un modelo propuesto. En verificación de pronósticos, la destreza (skill) es siempre un concepto relativo: un modelo demuestra habilidad únicamente cuando supera de forma sistemática a un modelo de referencia establecido. En la práctica meteorológica es habitual emplear como referencias el pronóstico climatológico, la persistencia y los pronósticos aleatorios sin información, ya que fijan el umbral por debajo del cual un modelo carece de valor predictivo.

3.1 Rol de los modelos de referencia utilizados en este trabajo

Se implementaron tres modelos de referencia, cada uno orientado a evaluar al modelo LIF desde un ángulo distinto:

Sin destreza (aleatorio): ¿El modelo tiene destreza real, es decir, supera a la aleatoriedad?

Persistencia: ¿Puede anticipar el evento, o solo detecta lluvia cuando ya está ocurriendo?

Regresión logística (sin memoria): ¿La memoria temporal del LIF aporta una ventaja frente a una combinación instantánea de las mismas entradas?

Los tres modelos reciben las mismas entradas normalizadas, se ajustan o calibran con el mismo esquema de partición (Ajuste, Calibración y Validación) y se evalúan sobre la misma ventana de Validación con las mismas métricas (CSI, FAR y POD), garantizando comparaciones objetivas.

Se implementó en el modelo sin destreza un pronóstico aleatorio Bernoulli, utilizando la

semilla (seed = 42) para garantizar la reproducibilidad.

El modelo de persistencia predice lluvia en t+1 si la precipitación observada en la hora actual supera el umbral que define el evento:
f{t+1} = 1 si prcp[t] ≥ 0,2 mm/h ; f{t+1} = 0 en caso contrario.

4 Adaptación modelo LIF

El modelo LIF se adapta como un detector de anomalías temporales sobre las variables meteorológicas normalizadas. No contiene ninguna componente aleatoria ni probabilística: el potencial V[t] se obtiene mediante una regla de recurrencia exacta y su valor queda completamente determinado por la entrada y por los parámetros fijos (τ y θ).
Cada variable se integra con su constante de tiempo para identificar si su valor es alto o persistente respecto de lo esperado para la época del año, y un mecanismo de alerta integra esas señales (junto con el contexto temporal) para emitir una alerta binaria de lluvia en la hora siguiente.

4.1 Versiones

Para evaluar el aporte de las propiedades del LIF se construyen cuatro versiones que combinan dos arquitecturas con la inclusión o exclusión de la variable precipitación:

LIF-A: Una neurona por variable y una neurona de alerta, sin precipitación como entrada: cinco variables (seis características al descomponer el viento en u y v)

[1, S_rhum, S_temp, S_pres, S_wspd, S_u, S_v, sin_doy, cos_doy, sin_hora, cos_hora]

(bias + 6 spikes de los sensores + 4 de contexto)

LIF-B: Una neurona por variable y neurona de alerta, con precipitación como entrada: seis variables (siete características al descomponer el viento en u y v)

[1, S_rhum, S_temp, S_pres, S_wspd, S_u, S_v, S_prcp, sin_doy, cos_doy, sin_hora, cos_hora]

(bias + 7 spikes + 4 contexto)

LIF-C: Neurona única de alerta, sin precipitación como entrada: cinco variables (seis características al descomponer el viento en u y v)

[1, rhum_anom, temp_anom, pres_anom, wspd_robust, u_viento, v_viento, sin_doy, cos_doy, sin_hora, cos_hora]

(bias + 6 variables normalizadas + 4 contexto)

LIF-D: Neurona única de alerta, con precipitación como entrada: seis variables (siete características al descomponer el viento en u y v)

[1, rhum_anom, temp_anom, pres_anom, wspd_robust, u_viento, v_viento, prcp_log, sin_doy, cos_doy, sin_hora, cos_hora]

(bias + 7 variables normalizadas + 4 contexto)

La neurona de alerta adopta la dinámica de integración con fuga del LIF (ecuación de membrana discretizada, EMA) con decisión por umbral, pero no emite spikes ni reinicia su potencial; el disparo con reinicio, característico del LIF, se emplea en la capa de sensores de la arquitectura de doble capa. En la neurona única, el modelo se reduce a un integrador con fuga (filtro exponencial) con umbral.

4.2 Arquitectura de una neurona por variable (LIF A y B)

4.2.1 Neuronas sensor (sufijo i)

Cada variable meteorológica $\hat{x}_i$ (normalizada) ingresa a una neurona LIF propia que integra su potencial con fuga y emite un spike binario cuando supera su umbral:

$V_i[t] = \alpha_i \cdot V_i[t-1] + (1-\alpha_i)\cdot \hat{x}_i[t]$,
donde $\alpha_i = \exp(-1/\tau_i)$

Las entradas de esta capa son las variables meteorológicas normalizadas (humedad relativa, temperatura, presión atmosférica, velocidad del viento, componentes u y v de la dirección del viento, y precipitación; esta última ausente en LIF-A). Cada sensor detecta si su variable presenta un valor alto o persistente respecto de lo esperado para la época del año.

$S_i[t] = 1$ si $V_i[t] \geq \theta_i$, con reinicio total $V_i[t] \leftarrow 0$

Parámetros de las neuronas sensor:
τ_i (constante de tiempo) fija por variable. Interpretada en horas según el tiempo que requiere cada variable para formar una persistencia temporal anómala detectable; Humedad relativa = 1h, temperatura = 2h, presión atmosférica = 2h, velocidad del viento = 2h, dirección del viento (u=2h, v=2h, 2 neuronas individuales), precipitación = 3h.

θ_i (umbral de disparo) aprendida por búsqueda de hiperparámetros. Se define como el percentil de la activación subumbral del sensor sobre el conjunto Ajuste. Se utiliza un único percentil compartido por todas las variables (rango entre 40–95, con incremento 5), ya que optimizar cada θ_i individualmente provocaría una explosión combinatoria.

4.2.2 Neurona de alerta (sufijo A)
El readout de la segunda capa combina linealmente los spikes de los sensores y el contexto para producir la evidencia escalar I[t]; la neurona de alerta integra esa evidencia con una memoria exponencial (EMA escalar) y emite la alerta cuando el potencial V_A supera el umbral sin reiniciar su potencial:

$I[t] = b + \Sigma_i w_i \cdot S_i[t] + \Sigma_j v_j \cdot ctx_j[t]$
(evidencia escalar instantánea)

En cada instante t, el readout recibe los spikes generados por las neuronas sensor (sección 4.2.1) y el contexto temporal: seno y coseno de la hora y del día del año.

$V_A[t] = \alpha_A \cdot V_A[t-1] + (1-\alpha_A)\cdot I[t]$,
$\alpha_A = \exp(-1/\tau_A)$
(memoria de la alerta: EMA escalar sobre la evidencia)

alerta[t] = 1 si $V_A[t] \geq \theta_A$, sin reinicio.

La memoria se aplica sobre la evidencia combinada, no sobre cada spike por separado: primero se ponderan los spikes con los pesos aprendidos y luego se suaviza en el tiempo el resultado escalar. El umbral θ_A se define como un percentil del potencial de alerta V_A en Calibración.

Parámetros:
τ_A (constante de tiempo de la alerta): aprendida por búsqueda de hiperparámetros. Rango entre 0,5–12 h, incremento 0,5 h.

θ_A (umbral de disparo): aprendida por búsqueda de hiperparámetros. Percentil del potencial de alerta en Calibración (rango entre 40–95, con incremento 5).

w_i, v_j, b: pesos del readout (spikes de las neuronas sensor, contexto y sesgo), aprendidos por regresión logística.

4.3 Arquitectura de neurona única (LIF C y D)
Las variables normalizadas ingresan directamente (sin neuronas sensor) a la neurona de alerta, que aplica la misma lógica: el readout produce la evidencia escalar

$I[t] = b + \Sigma_i w_i \cdot \hat{x}_i[t] + \Sigma_j v_j \cdot ctx_j[t]$

La memoria de la alerta la suaviza con el EMA escalar,

$V_A[t] = \alpha_A \cdot V_A[t-1] + (1-\alpha_A)\cdot I[t]$

y la alerta se emite según:
alerta[t] = 1 si $V_A[t] \geq \theta_A$

En cada instante t, la neurona única recibe las variables meteorológicas normalizadas y el contexto temporal (seno y coseno de la hora y del día del año); la precipitación está ausente en LIF-C.

Parámetros y rangos idénticos a la alerta de la doble capa; no existen θ_i ni τ_i.

4.3.1 Aclaración del modelo

A diferencia de la capa de sensores de la arquitectura de doble capa, esta neurona no emite un spike interno ni reinicia su potencial tras la alerta: su salida es la propia decisión binaria sobre un potencial que continúa integrando la evidencia (no se aplica reinicio ni período refractario, para no descartar información). En esta arquitectura, el carácter LIF se conserva en la integración con fuga y la decisión por umbral; el disparo con reinicio es propio de la capa de sensores de la doble capa.

4.4 Entrenamiento de los pesos y búsqueda de hiperparámetros

Regresión logística con Armijo: Los pesos del readout se obtienen minimizando la entropía cruzada binaria sobre el conjunto de "Ajuste" mediante descenso de gradiente con búsqueda de línea de Armijo (backtracking), se impuso una parada (criterio de convergencia) por norma del gradiente (tol 1e-12, máximo 1000 iteraciones). [9] En la versión "neurona por variable" los pesos se entrenan sobre los spikes generados por los sensores (simulados con memoria); en la "neurona única", sobre las variables normalizadas. [10]

Búsqueda descompuesta: El entrenamiento de los pesos está desacoplado de la búsqueda de los umbrales: los pesos no dependen de τ_A ni de θ_A, por lo que se entrenan una sola vez por configuración de sensores y la búsqueda posterior evalúa únicamente la alerta sobre potenciales ya calculados. [11]

Los pesos forman un subproblema convexo independiente de τ_A y θ_A. Los pesos se entrenan minimizando la entropía cruzada binaria sobre el Ajuste, objetivo que depende solo de (w, x, y). Como I[t] es lineal en w y la BCE es estrictamente convexa en w, el óptimo es único y su gradiente no contiene a τ_A ni a θ_A. Ningún parámetro de la etapa de alerta aparece en la etapa de pesos.

El disparo de las neuronas sensor es un escalón de Heaviside, $S_i[t] = 1$ si $V_i[t] \geq \theta_i$, cuya derivada es nula en casi todos los puntos y no está definida en el umbral [12]. Por la regla de la cadena, los parámetros aguas arriba del spike (τ_i y θ_i) no tienen gradiente útil respecto de la pérdida, por lo que no se entrenan por descenso de gradiente: τ_i se fija por criterio físico y θ_i se elige por búsqueda de hiperparámetros. La búsqueda de línea de Armijo se aplica únicamente a los pesos del readout, que están aguas abajo del spike.

Búsqueda de hiperparámetros: Cada combinación candidata de hiperparámetros se prueba sobre el conjunto de Calibración (2023) mediante una búsqueda en grilla para determinar la mejor combinación. El criterio de selección es máximo CSI en Calibración.

Doble capa: por cada percentil de sensor θ_i → se entrenan los pesos → por cada τ_A se simula la evidencia (Ajuste + Calibración) → por cada percentil θ_A se evalúan las métricas.

Neurona única: pesos una vez → por cada τ_A → por cada θ_A.
La mejor configuración se selecciona por máximo CSI en Calibración.

4.5 Simulación continua entre secciones

Se decidió inicializar la memoria del modelo con el conjunto de Ajuste, de modo que cada sección posterior parte del estado final de la anterior: en la arquitectura "neurona por variable" se heredan los potenciales de los sensores y el estado

escalar de la alerta (V_A); en la "neurona única" solo se hereda el estado escalar de la alerta (V_A). De este modo se utilizan todas las horas de Calibración y Validación, sin descartar horas de estabilización.

4.6 Otras decisiones de diseño

Codificación por inyección directa: los valores normalizados se inyectan como entradas analógicas continuas (corriente) en las neuronas. [2]

Sin período refractario: la neurona puede disparar en horas consecutivas. Con inyección directa horaria, un período refractario descartaría información esencial. [2]

5 Resultados y comparaciones

Se utilizaron las métricas CSI (Critical Success Index), FAR (False Alarm Ratio) y POD (Probability of Detection) para la comparación entre los modelos. [3]

5.1 Mejor configuración de calibración

LIF A: $\theta_i = 45$; τ_A (h) = 2,5; $\theta_A = 85$

LIF B: $\theta_i = 65$; τ_A (h) = 0,5; $\theta_A = 90$

LIF C: τ_A (h) = 0,5; $\theta_A = 80$

LIF D: τ_A (h) = 0,5; $\theta_A = 90$

Los umbrales son descritos en percentiles.

5.2 Métricas validación

Modelo	CSI	FAR	POD
LIF-A	0,169	0,762	0,368
LIF-B	0,403	0,484	0,648
LIF-C	0,211	0,758	0,620
LIF-D	0,339	0,527	0,545

Tabla 1. Métricas obtenidas luego de la validación de cada modelo LIF.

5.3 Métricas de los modelos de referencia

Referencia	CSI	FAR	POD
Persistencia	0,433	0,396	0,604
Sin destreza	0,028	0,940	0,049
Regresión logística (con prcp)	0,349	0,514	0,554
Regresión logística (sin prcp)	0,214	0,755	0,628

Tabla 2. Métricas obtenidas luego de evaluar los modelos de referencia.

6 Conclusión y Trabajos Futuros

El trabajo permitió demostrar empíricamente que el modelo LIF posee destreza real de detección: todas las versiones superaron en varias veces al baseline aleatorio, lo que indica que las anomalías integradas por las neuronas transportan información útil del evento.

Sin embargo, la hipótesis de que la memoria temporal del LIF proporcionaría una ventaja predictiva clara frente a los

modelos de referencia no se confirmó en la prueba actual. Frente a la persistencia, que obtuvo el CSI más alto del conjunto (0,433), ninguna versión LIF alcanzó su puntuación; frente a la regresión logística sin memoria, las diferencias resultaron reducidas: LIF-B (doble capa con precipitación) fue la única versión que superó a su contraparte con las mismas variables, con un CSI de 0,403 frente a 0,349 (Δ = 0,054), un FAR de 0,484 frente a 0,514 y un POD de 0,648 frente a 0,554. Así, LIF-B mejoró simultáneamente la detección (mayor POD) y la precisión de las alertas (menor FAR), aunque el margen en CSI fue escaso, por lo que no permite afirmar una ventaja concluyente. La comparación se realizó sobre 8783 horas de Validación, de las cuales 639 (7,3 %) correspondieron al evento objetivo; el Ajuste comprendió 43823 horas con 2633 eventos (6,0 %) y la Calibración 8759 horas con 728 eventos (8,3 %).

En cada sección se descartó la última observación, cuya etiqueta no es confirmable con los datos disponibles.

El efecto de la precipitación como entrada fue determinante: su inclusión elevó el CSI en la arquitectura de doble capa y neurona única. Este resultado es coherente con la importancia que el modelo asigna a dicha variable, su peso es el mayor en ambas arquitecturas (≈3,6 en LIF-B y ≈5,3 en LIF-D), de modo que su activación se convierte en el principal impulsor de la alerta. La doble capa de LIF-B permitió, mediante su neurona específica por variable, moderar esa influencia: alcanzó el menor FAR entre las versiones con precipitación y el mayor POD del conjunto de modelos. No obstante, todas las versiones presentan una proporción elevada de falsas alarmas (FAR entre 0,48 y 0,76), un error por predicción considerable que limita su aplicabilidad práctica. En conjunto, bajo el diseño y contexto actual no se demostró una ventaja general del LIF ni de su memoria temporal: sin la variable de precipitación, ninguna versión superó a la regresión logística (LIF-A 0,169 y LIF-C 0,211 frente a 0,214); con precipitación, solo LIF-B superó moderadamente a su contraparte de regresión logística, mientras que todas las versiones LIF permanecieron por debajo de la persistencia. Con respecto al optimizador, durante el entrenamiento eligió configuraciones que minimizan la memoria (τ_A (h) = 0.5) en todos los modelos excepto LIF-A donde τ_A (h) = 2.5, reforzando empíricamente que bajo este contexto la memoria no aportó una ventaja significativa.
Se observó, por lo tanto, una mejora puntual de una arquitectura frente a uno de los modelos de referencia, que resulta insuficiente para sostener una ventaja general de los modelos LIF.

Las principales limitaciones del trabajo fueron tres. Primero, la climatología se calculó con solo cinco años del conjunto de Ajuste, mientras que las normales climáticas se estiman convencionalmente sobre períodos de 30 años para minimizar el ruido del promedio, lo que puede degradar la calidad de las anomalías calculadas. [8] Segundo, se utilizó un único percentil de disparo compartido por todas las neuronas sensor, lo que impide ajustar el umbral óptimo de cada variable y puede perjudicar la precisión de los spikes generados. Tercero, la resolución horaria de los datos resulta insuficiente para captar cambios que, en las variables precursoras de la lluvia, ocurren en escalas de minutos, justificando la decisión del optimizador al asignar el mínimo valor disponible para τ_A. Estas limitaciones afectan directamente la calidad de las señales de entrada y, en consecuencia, condicionan los resultados obtenidos.

Como aporte, este trabajo evalúa una aplicación particular: el uso del LIF determinista como detector de anomalías para el pronóstico de precipitación. La investigación sienta una línea de base para comparar modelos espigantes con métodos estadísticos y de aprendizaje automático en esta tarea. Quedan abiertas cuestiones como

si la ventaja de la memoria temporal emerge con una resolución temporal más fina, con umbrales específicos por sensor o con variables precursoras adicionales. En consecuencia, los trabajos futuros se orientan a superar las limitaciones señaladas: estimar la climatología con períodos más extensos, optimizar un percentil de disparo por variable, incorporar datos de mayor frecuencia temporal y evaluar nuevas variables informativas relacionadas con la precipitación.

Si bien el LIF parece adecuado como mecanismo de detección temprana a corto plazo y demostró destreza real, se identificó una alta tasa de falsas alarmas en todas sus versiones, en consecuencia su utilidad como herramienta de pronóstico local permanece incierta; en su estado actual se recomienda un uso únicamente referencial. Los resultados plantean una base empírica sólida para continuar la investigación hacia una herramienta de pronóstico más precisa y confiable.

Agradecimientos:

Mi más sincero agradecimiento a la Prof. Ing. Paula Toselli por disponer de su tiempo en las correcciones y recomendaciones, como también al Prof. Ing. Sebastián Musetta por su disposición en aconsejarme durante el desarrollo de este trabajo.

Referencias

[1] Wenyue Wang and Klemens Hocke. Atmospheric Effects and Precursors of Rainfall over the Swiss Plateau. 2022: https://www.mdpi.com/2072-4292/14/12/2938

[2] Kass RE, et al. Computational Neuroscience: Mathematical and Statistical Perspectives. Annu Rev Stat Appl. 2018. Epub 2017: https://pmc.ncbi.nlm.nih.gov/articles/PMC6454918/

[3] Nota Técnica SMN 2024-167. Métodos propuestos para la evaluación de datos de precipitación medidos en estaciones automáticas: https://repositorio.smn.gob.ar/bitstream/handle/20.500.12160/2724/Nota_Tecnica_SMN_2024-167.pdf?sequence=1&isAllowed=y

[4] NOAA ISD: https://www.ncei.noaa.gov/products/land-based-station/integrated-surface-database

[5] Descomponer variable circular: https://arxiv.org/html/2512.03656v1

[6] Método de normalización z-score: https://openstax.org/books/introductory-statistics-2e/pages/6-1-the-standard-normal-distribution

[7] OMM-N° 8, Cap 6, Sección 6.1.1 y 6.1.2: https://library.wmo.int/viewer/68714/?offset=#page=266&viewer=picture&o=bookmark&n=0&q

[8] Cálculo climatología (OMM, Cap 3) https://library.wmo.int/viewer/60338/?offset=#page=13&viewer=picture&o=bookmark&n=0&q=

[9] Sharan Vaswani and Reza Babanezhad. Armijo Line-search Makes (Stochastic) Gradient Descent Go Fast. 2025: https://arxiv.org/html/2503.00229v1

[10] Regresión logística (IBM): https://www.ibm.com/mx-es/think/topics/logistic-regression

[11] Mantas Lukoševičius, Herbert Jaeger. Reservoir computing approaches to recurrent neural network training, Computer Science Review. 2009: https://www.sciencedirect.com/science/article/abs/pii/S1574013709000173

[12] Escalón de Heaviside: https://mathworld.wolfram.com/HeavisideStepFunction.html

Datos de Contacto:

Alexis Tomas Peralta, UTN FRVM, 5900, atperalta.ing@gmail.com